




下载APP



## 10 | 解析几何：为什么说它是向量从抽象到具象的表达？

2020-08-19 朱维刚

重学线性代数

[进入课程 >](#)**讲述：朱维刚**

时长 14:27 大小 13.24M



你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“解析几何”。

前面所有章节我们都是围绕向量、矩阵，以及向量空间来展开的。但这一节课有点不一样，我要讲的是解析几何，它使得向量从抽象走向了具象，让向量具有了几何的含义。比如，计算向量的长度、向量之间的距离和角度，这在机器学习的主成分分析 PCA 中是非常有用的。

### 范数



讲解析几何我们得从“范数”开始讲起。

因为很多人看到几何向量的第一反应就是，它是从原点开始的有向线段，并且向量的长度是这个有向线段的终端和起始端之间的距离。而范数，就是被用来度量某个向量空间或矩阵中的每个向量的长度或大小的。

现在，我们先来看一下范数的数学定义：一个向量空间  $V$  上的一个范数就是一个函数，它计算  $V$  中的每一个向量  $x$  的长度，用符号来表示的话就是： $\|x\| \in R$ ，它满足三种性质：

1. 正齐次性：如果输入参数扩大正  $\lambda$  倍，其对应的函数也扩大正  $\lambda$  倍。设  $\lambda \in R, x \in V$ ， $\|\lambda x\| = |\lambda| \|x\|$ ；
2. 次可加性：类似三角不等式，两边之和大于第三边。设  $x, y \in V$ ， $\|x + y\| \leq \|x\| + \|y\|$ ；
3. 正定性：向量  $x$  的长度一定大于等于零。 $\|x\| \geq 0$ 。

看到这里，你也许会问，范数似乎和以前老师教的**向量的模**一样啊。先别急，它们还真有那么一点关系，你听我慢慢道来。由于范数是度量某个向量空间或矩阵中的每个向量的长度或大小的，所以它和向量空间维度是有关系的，于是，我们可以把范数写成这样的模式来区分不同维度的大小计算： $L_1, L_2, \dots, L_\infty$ 。

$L_1$  范数：曼哈顿范数，也叫曼哈顿距离，设  $x \in R^n$ ，得到下面这个表达式。

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

$L_2$  范数：欧式范数，也叫欧式距离，设  $x \in R^n$ ，得到下面这个表达式。

$$\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$$

$L_\infty$  范数：切比雪夫范数，也叫切比雪夫距离，设  $x \in R^n$ ，得到下面这个表达式。

$$\|x\|_{\infty} = \max(|x_1|, |x_2|, \dots, |x_n|)$$

我们发现，向量的模和  $L_2$  范数的计算方式都是一样的，都表示的是欧氏距离，所以，我们可以简单地认为向量的模等于  $L_2$  范数。而其他的范数模式和向量的模则没有任何关系。

## 内积

学习解析几何时，我们必须掌握的第二个概念就是内积。

如果说范数是模式，是用来描述向量长度或大小的概念性表达，那么内积可以让我们很直观地了解一个向量的长度、两个向量之间的距离和角度，它的一个主要目的就是判断向量之间是否是正交的，正交这个概念我们会在后面讲解。

## 点积

我们从特殊到一般，先看点积，它和第三篇矩阵中说的“普通矩阵乘”形式一样，点积是特殊的内积，为什么说它特殊呢？那是因为在表示两个向量之间的距离时，它就是大家熟悉的欧式距离，点积可以表示成这样的形式：

$$x^T y = \sum_{i=1}^n x_i y_i$$

## 其他内积

除了点积外，我们再来看另一个不同的内积：设内积空间  $V$  是  $R^2$ ，定义内积  $\langle x, y \rangle = x_1 y_1 - (x_1 y_2 + x_2 y_1) + 2x_2 y_2$ ，一看便知这个和点积完全不同。

## 内积空间

最后，我们再来看一般内积和内积空间。因为解析几何关注的是向量的长度、两个向量之间的距离和角度，所以，我们要在原来向量空间上加一个额外的结构，这个额外结构就是内积，而加了内积的向量空间，我们就叫做内积空间。

为了表达方便，我们可以把内积写成  $\langle \cdot, \cdot \rangle$  这样的形式，那么内积空间  $V$  可以被表示成这样： $(V, \langle \cdot, \cdot \rangle)$ 。这时，如果一般内积由点积来表达，那这个向量空间就变成了更具体的欧式向量空间。

接下来看下内积空间有什么性质？我们定义一个内积空间  $V$  和它的元素  $x, y, z$ ，以及一个  $c \in R$ ：

满足对称性： $x$  和  $y$  的内积等于  $y$  和  $x$  的内积， $\langle x, y \rangle = \langle y, x \rangle$ ；

满足线性性： $x$  和  $y + cz$  的内积等于， $x$  和  $y$  的内积，与  $x$  和  $z$  的内积乘以  $c$  后的和，

$$\langle x, y + cz \rangle = \langle x, y \rangle + c\langle x, z \rangle;$$

满足正定性： $x$  和  $y$  的内积大于等于零， $\langle x, y \rangle \geq 0$ 。

## 对称正定矩阵

内积还定义了一类矩阵，这类矩阵在机器学习中很重要，因为它可以被用来判定多元函数极值，而在深度学习中，它更是被用来获取最小化损失函数，我们把这类矩阵叫做对称正定矩阵。

对称正定矩阵的定义是：如果一个对称矩阵  $A$  属于方阵  $R^{n \times n}$ ，对任意非零向量  $x$ ，都有  $x^T A x > 0$ ，那么  $A$  就是对称正定矩阵。

我们来看两个例子，判断它们是不是对称正定矩阵。

第一个例子，请你回答下面这个矩阵是对称正定矩阵吗？

$$A = \begin{bmatrix} 9 & 6 \\ 6 & 5 \end{bmatrix}$$

答案：是的，它是对称正定矩阵。因为  $x^T A x > 0$ 。

$$x^T A x = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 9 & 6 \\ 6 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = (3x_1 + 2x_2)^2 + x_2^2 > 0$$

第二个例子，请你看下面这个矩阵是对称正定矩阵吗？

$$A = \begin{bmatrix} 9 & 6 \\ 6 & 3 \end{bmatrix}$$

答案：不是的，它只是对称矩阵。因为  $x^T Ax$  可能小于 0。

$$x^T Ax = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 9 & 6 \\ 6 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = (3x_1 + 2x_2)^2 - x_2^2$$

## 长度、距离和角度

前面我们通过范数讲了向量的长度，但从内积的角度来看，我们发现，内积和范数之间有着千丝万缕的关系。我们来看看下面这个等式。

$$\|x\| = \sqrt{\langle x, x \rangle}$$

从这个等式我们发现，内积可以用来产生范数，确实是这样。不过，不是每一个范数都能被一个内积产生的，比如：曼哈顿范数。接下来，我们还是来关注能由内积产生的范数上，从不同的角度来看几何上的长度、距离和角度的概念。

我们先用内积来计算一个**向量的长度**，比如：向量  $x = \begin{bmatrix} 1 & 1 \end{bmatrix}^T$ ，我们可以使用点积来计算，计算后得出  $x$  的范数是  $\sqrt{2}$ ，具体计算过程是这样的： $\|x\| = \sqrt{x^T x} = \sqrt{1^2 + 1^2} = \sqrt{2}$ 。

接着，我们再来看一下**向量之间的距离**，一个内积空间  $V, (V, \langle \cdot, \cdot \rangle)$ ， $x$  和  $y$  是它的两个向量，那么  $x$  和  $y$  之间的距离就可以表示成： $d(x, y) = \|x - y\| = \sqrt{\langle x - y, x - y \rangle}$ 。

如果用点积来计算  $x$  和  $y$  之间的距离，那这个距离就叫做欧式距离。

再接着，来看看两个**向量之间的角度**。我们使用柯西 - 施瓦茨不等式 (Cauchy-Schwarz Inequality) 来表示内积空间中两个向量  $x$  和  $y$  之间的角度： $a$ 。

$$-1 \leq \frac{\langle x, y \rangle}{\|x\| \|y\|} \leq 1$$

取值是从  $-1$  到  $1$  之间，那么角度就是从  $0$  到  $\pi$  之间，我们用  $\cos$  来表示就是：

$$\cos(a) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$

其中  $a$  就是角度， $a$  的角度取值是  $0$  到  $\pi$  之间。我们很容易就能发现，其实两个向量之间的角度，就是告诉了我们两个向量之间方向的相似性。例如： $x$  和  $y = 4x$ ，使用点积来计算它们之间的角度是  $0$ ，也就是说它们的方向是一样的， $y$  只是对  $x$  扩大了  $4$  倍而已。


现在，我们通过一个例子，再来更清楚地看下两个向量之间角度的计算，设  $x = \begin{bmatrix} 1 & 1 \end{bmatrix}^T$ ， $y = \begin{bmatrix} 1 & 2 \end{bmatrix}^T$ ，使用点积来计算，我们得出：

$$\cos(a) = \frac{\langle x, y \rangle}{\sqrt{\langle x, x \rangle \langle y, y \rangle}} = \frac{x^T y}{\sqrt{x^T x y^T y}} = \frac{3}{\sqrt{10}}$$

那么，这两个向量之间的角度如下。


$$\arccos\left(\frac{3}{\sqrt{10}}\right) \approx 0.32$$

我们可以用图来更直观地表达一下。



于是，我们最后可以引出一个概念，也就是我们在一开始提到的**正交性**。如果两个向量  $x$  和  $y$  内积等于 0， $\langle x, y \rangle = 0$ ，那么  $x$  和  $y$  是正交的，这可以写成： $x \perp y$ 。再如果， $x$  和  $y$  的范数都等于 1， $\|x\| = \|y\| = 1$ ，也就是说，如果它们都是单位向量，那么  $x$  和  $y$  就是标准正交的。

我们用图来更直观地表达一下。



## 正交投影


在理论讲解之后，我们要来了解一下解析几何在实践中经常运用的概念——正交投影，它是一种重要的线性变换，在图形图像、编码理论、统计和机器学习中扮演了重要角色。

在机器学习中，数据一般都是高维的。众所周知，高维数据是很难来分析和可视化的。而且，不是所有的高维数据都是有用的，可能只有一些数据包含了大部分的重要信息。

正交投影就是高维到低维的数据投影，在🔗[第 5 节课线性空间](#)中，我简单介绍了高维数据投影到低维后，我们就能在低维空间更多地了解数据集、提炼相关模式。而在机器学习中，最普遍的降维算法——PCA 主成分分析，就是利用了降维的观点。

接下来，我开始讲解正交投影，在给出定义之前，先从一张图来了解会更直观。






图中的蓝点是原二维数据，黄点是它们的正交投影。所以，实际降维后，在一维空间中就形成了这条黑线表示，它近似地表达了原来二维数据表示的信息。

现在我们可以来看一下投影的定义： $V$  是一个向量空间， $U$  是  $V$  的一个向量子空间，一个从  $V$  到  $U$  的线性映射  $\Phi$  是一个投影，如果它满足： $\Phi^2 = \Phi \circ \Phi = \Phi$ 。因为线性映射能够被变换矩阵表示，所以，这个定义同样适用于一个特殊类型变换矩阵：投影矩阵  $P_\Phi$ ，它也满足： $P_\Phi^2 = P_\Phi$ 。

## 投影到一维子空间上（线）

接下来，我们来看看如何投影到一维子空间，也就是把内积空间的向量正交投影到子空间，这里我们使用点积作为内积。

假设有一条通过原点的线，这条线是由基向量  $b$  产生的一维子空间  $U$ ，当我们把一个向量  $x$  投影到  $U$  时，需要寻找另一个最靠近  $x$  的向量  $\Phi_U(x)$ 。还是老样子，我们通过图来看一下。



首先，投影  $\Phi_U(x)$  靠近  $x$ ，也就是要找出  $x$  和  $\Phi_U(x)$  之间的  $\|x - \Phi_U(x)\|$  最小距离，从几何角度来说，就是线段  $\Phi_U(x) - x$  和  $b$  正交，满足等式： $\langle \Phi_U(x) - x, b \rangle = 0$ 。其次，投影  $\Phi_U(x)$  必须是  $U$  的一个元素，也就是，基向量  $b$  的一个乘来产生  $U$ ， $\Phi_U(x) = \lambda b$ 。

于是，我们可以通过三个步骤来分别得到  $\lambda$ 、投影  $\Phi_U(x)$  和投影矩阵  $P_\Phi$ ，来把任意  $x$  映射到子空间  $U$  上。

第一步，计算  $\lambda$ ，通过正交条件产生这样的等式：

$$\langle x - \Phi_U(x), b \rangle = 0。因为 \Phi_U(x) = \lambda b, 所以它可以转变成: \langle x - \lambda b, b \rangle = 0。$$

利用内积的双线性： $\langle x, b \rangle - \lambda \langle b, b \rangle = 0$ ，我们得到：

$$\lambda = \frac{\langle x, b \rangle}{\langle b, b \rangle} = \frac{\langle b, x \rangle}{\|b\|^2}$$

然后，我们通过点积得到：

$$\lambda = \frac{b^T x}{\|b\|^2}$$

如果  $\|b\| = 1$ ，那  $\lambda$  就等于  $b^T x$ 。

接着第二步，是计算投影点  $\Phi_U(x)$ 。从  $\Phi_U(x) = \lambda b$ ，我们得到：

$$\Phi_U(x) = \lambda b = \frac{\langle x, b \rangle}{\|b\|^2} b = \frac{b^T x}{\|b\|^2} b$$

通过点积来计算，我们就得到了  $\Phi_U(x)$  的长度：

$$\|\Phi_U(x)\| = \frac{|b^T x|}{\|b\|^2} \|b\| = |\cos(a)| \|x\| \|b\| \frac{\|b\|}{\|b\|^2} = |\cos(a)| \|x\|$$

这里的  $a$ ，是  $x$  和  $b$  之间的夹角。

最后第三步，是计算投影矩阵  $P_\Phi$ ，投影矩阵是一个线性映射。所以，我们可以得到：

$\Phi_U(x) = P_\Phi x$ ，通过  $\Phi_U(x) = \lambda b$ ，我们可以得到：

$$\Phi_U(x) = \lambda b = b \lambda = b \frac{b^T x}{\|b\|^2} = \frac{b b^T}{\|b\|^2} x$$

这里，我们立即可以得到投影矩阵  $P_\Phi$  的计算等式：

$$P_{\Phi} = \frac{bb^T}{\|b\|^2}$$

## 本节小结

这一节课覆盖的知识点有点多，因为要把解析几何的知识点，浓缩到核心的几个点来讲解是一项艰巨的任务。不过不要怕，前面的几个知识点都是为这一节的重点“正交投影”来铺垫的。范数，被用来度量某个向量空间或矩阵中的每个向量的长度或大小，而内积让我们很直观地了解一个向量的长度、两个向量之间的距离和角度，以及判断向量之间是否是正交的。

所以，希望你能掌握范数和内积的理论知识，并把它和正交投影结合，运用在一些实践应用场景中，比如：3D 图形图像的坐标变换、数据压缩，以及机器学习的降维。

## 线性代数练习场

请用之前学到的正交投影的投影矩阵算法，来计算一条线上的投影矩阵  $P_{\Phi}$ 。

这条线通过原点，由基  $b = \begin{bmatrix} 1 & 2 & 2 \end{bmatrix}^T$  产生， $P_{\Phi}$  计算后，再通过一个  $x$  来验证一下它是否在  $b$  产生的子空间中，我们取  $x = \begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^T$ 。

欢迎在留言区晒出你的运算结果，我会及时回复。同时，也欢迎你把这篇文章分享给你的朋友，一起讨论、学习。

提建议

更多课程推荐

# MySQL 实战 45 讲

从原理到实战，丁奇带你搞懂 MySQL

林晓斌

网名丁奇  
前阿里资深技术专家



立省 ¥30

今日秒杀 ¥99，5.8W 人在学

© 版权归极客邦科技所有，未经许可不得传播售卖。页面已增加防盗追踪，如有侵权极客邦将依法追究其法律责任。

上一篇 09 | 仿射空间：如何在图形的平移操作中大显身手？

下一篇 基础通关 | 线性代数5道典型例题及解析

## 精选留言 (2)

写留言



Dr.z

2020-08-20

老师 问一下

$\Phi^2 = \Phi \circ \Phi = \Phi$

这里的空心圆 代表了什么操作？

展开

作者回复: 你好，Dr.z，这里的空心圆表示的是幂等。



那一刻

2020-08-19

请教老师两个问题，

1. 对称正定矩阵在深度学习中，被用来获取最小化损失函数。是因为正定矩阵可逆来求解吗？麻烦老师具体说一下
2. 投影矩阵P和SVM算法里的支持向量到超平面的距离看着蛮相似的，不知道这么理解...  
展开 ∨

作者回复: 那时刻同学，很好的两个问题。

1. 从深度学习来理解对称正定矩阵，就是所有特征值都是正数的对称矩阵，推荐看下这篇文章详细说了深度学习中的对称正定矩阵，从图形看更明显，因为目前回复不支持富文本，可以看看这篇文章。<https://zhuanlan.zhihu.com/p/112772023>
2. 是的，没错，只不过是在不同的维度空间来看投影，超平面是在 $n-1$ 维，第9篇也介绍了一下超平面和它的参数方程。

